

**ANALISIS KARAKTERISTIK SPEKTRAL SINYAL AUDIO DEEPPAKE
MENGUNAKAN METODE SHORT-TIME FOURIER TRANSFORM (STFT)**



Disusun Oleh:

Mohammad Tyas Subianto 24031554077

Daris Ikhwana Khoir Suhaya 24031554215

Dosen Pengampu:

Yuni Rosita Dewi, M.Si.

Dr. Heri Purnawan, S.Si., M.Si.

**PROGRAM STUDI S1 SAINS DATA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS NEGERI SURABAYA**

2025

DAFTAR ISI

DAFTAR ISI.....	2
BAB I.....	4
PENDAHULUAN.....	4
1.1 Latar Belakang.....	4
1.2 Rumusan Masalah.....	5
1.3 Tujuan.....	5
1.4 Manfaat.....	5
BAB II.....	6
LANDASAN TEORI.....	6
2.1 Deepfake Audio dan Mekanisme Generative AI.....	6
2.2 Karakteristik Sinyal Wicara (Speech Signal).....	6
2.3 Short-Time Fourier Transform (STFT).....	6
2.4 Convolutional Neural Network (CNN) untuk Klasifikasi Audio.....	7
2.5 Analisis Artifak Spektral.....	7
2.6 Mel Spectrogram.....	7
BAB III.....	9
METODE.....	9
3.1 Alat dan Bahan.....	9
3.1.1 Pemilihan Versi Dataset.....	9
3.1.2 Struktur Pembagian Data.....	9
3.2 Alur Penelitian.....	10
3.3 Pra-pemrosesan Sinyal (Signal Pre-processing).....	11
3.3.1 Penyeragaman Durasi (Time Domain).....	11
3.3.2 Transformasi Spektral (Log-Mel Spectrogram).....	11
3.3.3 Normalisasi Data.....	12
3.4 Perancangan Arsitektur Model (CNN).....	12
3.4.1 Struktur Lapisan Model.....	12
3.4.2 Konfigurasi Pelatihan (Hyperparameters).....	13
BAB IV.....	15
HASIL DAN PEMBAHASAN.....	15
4.1 Analisis Visual Karakteristik Sinyal.....	15
4.1.1 Perbandingan Domain Waktu dan Frekuensi.....	15
4.1.2 Komparasi Spektrogram: Asli vs Palsu (Real vs Fake).....	16
4.3 Evaluasi Kinerja Sistem (Testing Evaluation).....	18
4.3.1 Analisis Confusion Matrix.....	18
4.3.2 Classification Report.....	19
4.4 Pembahasan (Discussion).....	20
4.4.1 Analisis Pola Spektral Rata-Rata (Average Spectral Patterns).....	20
4.4.2 Analisis Distribusi Energi (Energy Distribution Statistics).....	21
4.4.3 Keterbatasan Model.....	23

BAB V	
PENUTUP.....	24
5.1 Kesimpulan.....	24
REFERENSI.....	25
LAMPIRAN.....	26

BAB I

PENDAHULUAN

1.1 Latar Belakang

Perkembangan teknologi kecerdasan buatan (Artificial Intelligence) saat ini telah mampu menciptakan tiruan suara manusia yang sangat mirip dengan aslinya, atau yang dikenal sebagai Deepfake Audio[1]. Teknologi ini bisa meniru suara seseorang hanya dengan mengetikkan teks (Text-to-Speech) atau mengubah suara orang lain menjadi target tertentu[2]. Hal ini menimbulkan ancaman serius, seperti penipuan dan penyebaran berita bohong, karena telinga manusia seringkali sulit membedakan mana suara asli dan mana suara buatan mesin[3].

Meskipun terdengar sempurna, suara buatan mesin sebenarnya memiliki cacat halus atau "jejak digital" yang tidak terdengar oleh telinga, tetapi bisa dilihat jika sinyal suaranya dibedah[4]. Oleh karena itu, diperlukan pendekatan Pengolahan Sinyal Digital (PSD) untuk menganalisis sinyal tersebut, bukan hanya melihat bentuk gelombangnya, melainkan melihat kandungan frekuensinya[5].

Metode yang digunakan untuk melihat kandungan frekuensi ini adalah Short-Time Fourier Transform (STFT)[6]. Metode ini mengubah sinyal suara menjadi gambar peta frekuensi yang disebut Spektrogram[7]. Dengan melihat Spektrogram, kita bisa mendeteksi adanya pola-pola aneh atau noise pada frekuensi tertentu yang menjadi ciri khas suara palsu[8].

Proyek ini bertujuan untuk menganalisis karakteristik sinyal Deepfake Audio menggunakan metode STFT tersebut. Fokus utamanya adalah menguji apakah Spektrogram cukup ampuh untuk membedakan suara asli dan palsu[9]. Untuk membantu proses pengujian, digunakan model komputer (CNN) sebagai alat validasi[10]. Analisis ini diharapkan dapat memberikan gambaran mengenai kemampuan metode analisis frekuensi dalam mengenali berbagai jenis teknik pemalsuan suara (deepfake) yang dilakukan secara digital[11].

1.2 Rumusan Masalah

1. Bagaimana karakteristik sinyal Deepfake Audio jika dilihat dari domain frekuensi menggunakan transformasi sinyal STFT (Short-Time Fourier Transform)?
2. Apakah terdapat perbedaan pola visual (artifak) yang signifikan dibandingkan dengan sinyal suara asli?
3. Seberapa efektifkah fitur spektral yang dihasilkan oleh metode STFT dalam membedakan suara asli dan palsu, terutama ketika sistem dihadapkan pada jenis serangan atau algoritma deepfake baru yang belum pernah dikenali sebelumnya ?

1.3 Tujuan

1. Menerapkan metode transformasi sinyal Short-Time Fourier Transform (STFT) untuk mengubah data audio mentah menjadi representasi visual (Spektrogram) yang dapat dianalisis frekuensinya.
2. Menganalisis perbedaan karakteristik sinyal antara suara asli dan Deepfake Audio dengan melihat pola distribusi energi dan noise pada tampilan Spektrogram.
3. Mengevaluasi kemampuan fitur spektral tersebut dalam mendeteksi pemalsuan suara, dengan membandingkan tingkat akurasi deteksi pada data yang sudah dipelajari (training) melawan data serangan baru yang belum dikenal (testing).

1.4 Manfaat

1. Memberikan bukti nyata mengenai penerapan ilmu Pengolahan Sinyal Digital (PSD), khususnya metode transformasi frekuensi (STFT), dalam memecahkan masalah keamanan modern.
2. Menambah wawasan literatur mengenai karakteristik visual sinyal Deepfake Audio pada domain frekuensi, serta sejauh mana fitur tersebut dapat diandalkan untuk membedakan suara asli dan palsu.

BAB II

LANDASAN TEORI

2.1 Deepfake Audio dan Mekanisme Generative AI

Deepfake audio adalah hasil sintesis suara manusia yang dihasilkan oleh kecerdasan buatan (Artificial Intelligence) menggunakan teknik Deep Learning. Teknologi ini umumnya terbagi menjadi dua kategori utama:

1. Text-to-Speech (TTS): Mengubah teks menjadi ucapan suara yang meniru target pembicara tertentu.
2. Voice Conversion (VC): Mengubah suara pembicara sumber menjadi suara target tanpa mengubah konten linguistiknya.

Algoritma modern seperti WaveNet, Tacotron, dan VALL-E menggunakan arsitektur Neural Vocoder untuk menghasilkan gelombang suara (waveform) mentah. Berbeda dengan suara manusia yang dihasilkan oleh getaran fisik pita suara dan resonansi saluran vokal, suara AI dihasilkan melalui prediksi probabilitas sampel audio berikutnya berdasarkan sampel sebelumnya. Proses komputasi ini, meskipun canggih, sering kali meninggalkan jejak ketidaksempurnaan atau anomali yang disebut "artifak" pada level mikro sinyal.

2.2 Karakteristik Sinyal Wicara (Speech Signal)

Dalam domain Pengolahan Sinyal Digital (PSD), sinyal wicara diklasifikasikan sebagai sinyal Non-Stasioner. Artinya, properti statistik dan kandungan frekuensi sinyal wicara berubah secara cepat terhadap waktu.

Metode transformasi frekuensi standar seperti Fast Fourier Transform (FFT) memiliki kelemahan jika diterapkan langsung pada seluruh durasi sinyal wicara, karena FFT menghilangkan informasi waktu (temporal information). FFT hanya memberitahu frekuensi apa yang ada, tetapi tidak memberi tahu kapan frekuensi tersebut muncul. Padahal, dalam deteksi deepfake, urutan kejadian dan perubahan frekuensi sesaat sangat krusial untuk dianalisis.

2.3 Short-Time Fourier Transform (STFT)

Untuk mengatasi sifat non-stasioner sinyal wicara, penelitian ini menggunakan metode Short-Time Fourier Transform (STFT).

STFT bekerja dengan prinsip "jendela waktu" (*windowing*), di mana sinyal panjang dipotong menjadi segmen-segmen pendek yang saling tumpang tindih (*overlapping*). Magnitudo kuadrat dari hasil STFT, yaitu $|STFT(m, \omega)|^2$, dikenal sebagai Spektrogram. Spektrogram adalah representasi visual 2D di mana sumbu-X mewakili waktu, sumbu-Y mewakili frekuensi, dan intensitas warna (atau kecerahan) mewakili amplitudo (energi) sinyal dalam skala desibel.

2.4 Convolutional Neural Network (CNN) untuk Klasifikasi Audio

Meskipun CNN umumnya digunakan untuk pengolahan citra, metode ini sangat efektif untuk analisis audio yang telah diubah menjadi bentuk Spektrogram. Dalam konteks ini, spektrogram diperlakukan sebagai "citra" suara.

CNN bekerja dengan memindai fitur lokal pada spektrogram menggunakan kernel atau filter konvolusi. Keunggulan CNN dalam penelitian ini adalah kemampuannya mengenali pola spasial, seperti:

- Garis batas tegas pada frekuensi tertentu.
- Pola tekstur berulang pada distribusi energi.

Dalam source code yang diimplementasikan, CNN mengekstraksi fitur-fitur abstrak ini melalui lapisan konvolusi (Conv2D) dan mereduksi dimensi data melalui lapisan Pooling (MaxPooling2D) sebelum melakukan klasifikasi biner (Asli vs Palsu) pada Fully Connected Layer.

2.5 Analisis Artifak Spektral

Dasar deteksi keaslian suara dalam penelitian ini berfokus pada dua jenis anomali spektral yang dihasilkan oleh Generative AI:

1. Frequency Cut-off (Pemotongan Frekuensi Tiba-tiba):
Model Text-to-Speech (TTS) sering kali dilatih dengan dataset yang memiliki sample rate terbatas (misalnya 16 kHz atau 22 kHz). Ketika model ini menghasilkan suara, ia cenderung gagal merekonstruksi frekuensi di atas batas tersebut, menciptakan area kosong (void) yang tidak wajar pada frekuensi tinggi. Pada suara manusia asli, energi frekuensi cenderung meluruh secara alami (gradual), bukan terpotong tajam.
2. Checkerboard Artifacts (Pola Papan Catur):
Artifak ini muncul akibat proses Upsampling pada lapisan Transposed Convolution di dalam arsitektur Neural Network pembuat suara. Ketika ukuran stride (langkah geser) dan ukuran kernel tidak selaras sempurna, terjadi tumpang tindih sinyal yang tidak merata, menciptakan pola garis-garis vertikal dan horizontal yang menyerupai papan catur pada spektrogram. Pola ini tidak pernah ditemukan pada rekaman suara manusia organik.

2.6 Mel Spectrogram

Meskipun STFT mampu merepresentasikan sinyal audio dalam domain waktu–frekuensi secara detail, representasi frekuensi linear yang dihasilkan oleh STFT belum sepenuhnya selaras dengan cara manusia mempersepsikan bunyi. Sistem pendengaran manusia memiliki sensitivitas yang lebih tinggi terhadap perbedaan frekuensi rendah dibandingkan frekuensi

tinggi. Untuk mengakomodasi karakteristik persepsi ini, digunakan pendekatan Mel Spectrogram.

Mel Spectrogram merupakan pengembangan dari spektrogram STFT yang memetakan sumbu frekuensi linear ke dalam skala Mel, yaitu skala frekuensi non-linear yang dirancang untuk mendekati persepsi pendengaran manusia.

Dalam pembentukan Mel Spectrogram, hasil STFT terlebih dahulu dihitung, kemudian magnitudo spektrum tersebut dilewatkan melalui sekumpulan Mel filter bank. Setiap filter berbentuk segitiga dan terdistribusi secara tidak merata, dengan resolusi frekuensi yang lebih rapat pada frekuensi rendah dan lebih jarang pada frekuensi tinggi. Proses ini menghasilkan representasi spektral yang lebih ringkas dan relevan secara perceptual.

Keunggulan Mel Spectrogram dalam analisis audio, khususnya pada deteksi suara sintetis (deepfake audio), adalah kemampuannya untuk:

1. Menekankan informasi frekuensi rendah, yang berkaitan erat dengan karakteristik pitch dan formant suara manusia.
2. Mereduksi dimensi data spektral, sehingga lebih efisien untuk dianalisis dan diproses.
3. Menonjolkan pola spektral yang stabil secara perseptual, sehingga perbedaan antara suara asli dan suara sintetis menjadi lebih mudah diamati.

Dalam konteks penelitian ini, Mel Spectrogram digunakan sebagai representasi spektral lanjutan dari STFT untuk menganalisis artifak spektral yang dihasilkan oleh sistem Generative AI. Artifak seperti frequency cut-off dan checkerboard artifacts tetap dapat diamati pada Mel Spectrogram, namun dalam bentuk yang lebih terstruktur dan lebih sesuai dengan persepsi pendengaran manusia. Oleh karena itu, Mel Spectrogram menjadi representasi yang efektif baik untuk analisis visual maupun sebagai masukan bagi sistem klasifikasi berbasis Convolutional Neural Network (CNN).

BAB III METODE

3.1 Alat dan Bahan

Data utama yang digunakan dalam penelitian ini adalah The Fake-or-Real (FoR) Dataset. Dataset ini merupakan kumpulan file audio yang dirancang khusus untuk menguji kemampuan sistem dalam membedakan suara manusia asli (Real) dan suara sintetis buatan AI (Fake/Deepfake).

3.1.1 Pemilihan Versi Dataset

Dalam publikasi aslinya, penyedia dataset FoR sebenarnya menyediakan beberapa variasi data untuk kebutuhan yang berbeda, antara lain:

1. for-original: Berisi file audio asli dengan durasi yang bervariasi (tidak seragam), mulai dari hitungan detik hingga menit.
2. for-norm: Versi yang sudah dinormalisasi volume dan sample rate-nya.
3. for-2seconds: Versi yang sudah dipotong-potong secara presisi menjadi durasi tepat 2 detik.

Pada penelitian ini, varian yang dipilih adalah for-2seconds. Pemilihan ini didasarkan pada alasan teknis pengolahan sinyal. Dalam metode analisis frekuensi (STFT) dan jaringan saraf tiruan (CNN), keseragaman input adalah syarat mutlak. Jika kita menggunakan versi original yang panjangnya acak, kita harus melakukan pemotongan manual yang berisiko membuang informasi penting atau menyisakan silence (hening) yang tidak perlu.

Dengan menggunakan versi for-2seconds, kita memastikan bahwa setiap sampel memiliki "jatah" waktu dan jumlah piksel frekuensi yang sama persis. Durasi 2 detik juga dianggap sebagai durasi ideal: cukup panjang untuk menangkap pola intonasi dan noise frekuensi, tetapi cukup pendek untuk menjaga proses komputasi tetap ringan.


3.1.2 Struktur Pembagian Data

Dataset ini sudah terbagi secara terstruktur ke dalam tiga folder terpisah untuk menjaga objektivitas pengujian, yaitu:

- Training (Latih): Digunakan untuk mengajarkan model mengenali ciri-ciri suara asli vs palsu.
- Validation (Validasi): Digunakan untuk memantau proses belajar agar model tidak sekadar menghafal jawaban.
- Testing (Uji): Digunakan sebagai "ujian akhir" dengan data yang belum pernah dilihat model sebelumnya, untuk mengukur akurasi nyata di lapangan.

3.2 Alur Penelitian

Secara garis besar, tahapan penelitian ini dirancang untuk mengubah sinyal suara yang abstrak menjadi data visual yang bisa dipahami oleh komputer. Alur penelitian dibagi menjadi empat tahapan utama seperti yang tergambarkan dalam diagram alir berikut:



Gambar 2.1 Alur Proyek

Berikut adalah penjelasan detail dari setiap tahapan yang dilakukan:

1. Pengumpulan & Pemuatan Data (Data Loading): Sistem membaca ribuan file audio .wav dari folder dataset. Pada tahap ini, semua audio dipastikan memiliki sample rate yang seragam yaitu 16.000 Hz (16 kHz). Angka ini dipilih karena cukup untuk menangkap frekuensi suara manusia tanpa membebani memori komputer.
2. Pra-pemrosesan Sinyal (Pre-processing): Sebelum dianalisis, sinyal audio harus "dirapikan" dulu.
 - Penyeragaman Durasi: Audio yang lebih dari 2 detik dipotong, dan yang kurang dari 2 detik ditambahkan hening (padding) agar ukurannya sama persis.
 - Normalisasi Amplitudo: Volume suara disetarakan agar tidak ada data yang terlalu pelan atau terlalu keras, yang bisa mengganggu proses belajar model.
3. Transformasi Sinyal (Ekstraksi Fitur): Ini adalah inti dari proses Pengolahan Sinyal Digital. Sinyal suara yang tadinya berupa gelombang waktu, diubah menjadi Log-Mel Spectrogram.
 - Kita menggunakan transformasi STFT untuk melihat frekuensinya.
 - Lalu frekuensi tersebut dipetakan ke Skala Mel (sesuai pendengaran manusia).
 - Terakhir, intensitasnya diubah ke skala Desibel (dB) agar suara-suara artifak yang lirih (ciri khas deepfake) bisa terlihat jelas.

4. Klasifikasi Pola (CNN): Gambar spektrogram hasil transformasi tadi dimasukkan ke dalam model kecerdasan buatan (CNN). Model ini bertugas mencari pola unik (seperti garis-garis kasar atau noise) yang membedakan suara asli dan palsu.
5. Evaluasi Kinerja: Terakhir, sistem diuji menggunakan data baru (Testing Set) yang belum pernah dilihat sebelumnya untuk menghitung seberapa akurat tebakannya.

3.3 Pra-pemrosesan Sinyal (Signal Pre-processing)

Sebelum data dimasukkan ke dalam model kecerdasan buatan, sinyal audio mentah harus melalui serangkaian tahapan pengolahan sinyal agar informasinya dapat dibaca dengan baik. Proses ini merupakan inti dari penerapan teori Pengolahan Sinyal Digital dalam penelitian ini.

3.3.1 Penyeragaman Durasi (Time Domain)

Model Convolutional Neural Network (CNN) membutuhkan input dengan dimensi yang tetap. Oleh karena itu, setiap file audio dipastikan memiliki durasi tepat 2 detik.

- Pemotongan (Truncating): Jika audio lebih panjang dari 2 detik, sinyal akan dipotong di bagian akhir.
- Pengisian (Padding): Jika audio kurang dari 2 detik, akan ditambahkan nilai nol (silence) di bagian akhir hingga mencapai durasi target. Proses ini memastikan bahwa setiap data memiliki jumlah sampel waktu yang sama.

3.3.2 Transformasi Spektral (Log-Mel Spectrogram)

Ini adalah tahapan krusial di mana sinyal diubah dari domain waktu ke domain frekuensi. Penelitian ini tidak menggunakan STFT biasa, melainkan Mel-Spectrogram untuk meniru cara kerja telinga manusia yang lebih sensitif pada frekuensi rendah.

Berikut adalah parameter matematis yang digunakan dalam transformasi ini:

1. Window Size (n_{fft}): 1024. Sinyal dibagi menjadi jendela-jendela kecil sepanjang 1024 sampel. Ukuran ini dipilih untuk mendapatkan keseimbangan yang baik antara resolusi waktu dan frekuensi.
2. Hop Length: 256. Pergeseran antar-jendela (overlap) diatur sebesar 256 sampel untuk memastikan transisi antar-waktu terlihat halus.
3. Mel Filter Banks (n_{mels}): 64. Frekuensi linear dipetakan ke dalam 64 pita frekuensi skala Mel. Ini berfungsi untuk membuang detail frekuensi tinggi yang kurang relevan dan memfokuskan analisis pada area di mana suara manusia (dan artifak deepfake) paling dominan.

4. Konversi Desibel (Log-Scale). Amplitudo hasil transformasi diubah ke skala Logaritma (dB) menggunakan rumus:

$$S_{dB} = 10 \cdot \log_{10}(S)$$

Tujuannya adalah untuk menonjolkan sinyal-sinyal lemah (seperti noise latar belakang atau artifak digital halus) yang biasanya menjadi ciri khas rekaman palsu.

3.3.3 Normalisasi Data

Setelah menjadi gambar spektrogram, nilai piksel (intensitas dB) dinormalisasi menggunakan teknik Min-Max Normalization. Seluruh nilai diubah ke rentang 0 sampai 1. Hal ini dilakukan agar model CNN dapat belajar dengan stabil dan tidak bias terhadap data yang volumenya terlalu keras atau terlalu pelan.

3.4 Perancangan Arsitektur Model (CNN)

Setelah sinyal audio diubah menjadi citra visual (Log-Mel Spectrogram), langkah selanjutnya adalah klasifikasi menggunakan algoritma Deep Learning. Arsitektur yang dipilih adalah Convolutional Neural Network (CNN).

Meskipun CNN umumnya digunakan untuk pengenalan objek pada foto (seperti membedakan kucing dan anjing), metode ini sangat efektif untuk audio. Alasannya sederhana: Spektrogram adalah representasi 2 dimensi (Waktu dan Frekuensi). Oleh karena itu, kita bisa menggunakan CNN untuk "melihat" pola-pola aneh atau artifak visual pada grafik frekuensi tersebut.

3.4.1 Struktur Lapisan Model

Model yang dibangun terdiri dari beberapa lapisan yang bekerja secara berurutan, dari mengekstraksi fitur kasar hingga mengambil keputusan akhir. Berikut adalah rinciannya:

1. Input Layer (Lapisan Masukan) Model menerima input berupa gambar spektral dengan dimensi (Waktu X Frekuensi Mel). Input ini ibarat "kanvas" yang akan diperiksa oleh model.
2. Convolutional Layers (Lapisan Ekstraksi Fitur) Ini adalah "mata" dari model. Terdapat 3 blok konvolusi yang digunakan secara bertahap:
 - Blok 1 (16 Filter): Mencari fitur sederhana, seperti garis tepi atau perubahan drastis pada frekuensi.
 - Blok 2 (32 Filter): Menggabungkan fitur sederhana menjadi pola yang lebih kompleks.

- Blok 3 (64 Filter): Mencari pola detail yang spesifik, seperti jejak noise kotak-kotak (checkerboard artifacts) yang sering ditinggalkan oleh algoritma deepfake.

Setiap lapisan ini menggunakan kernel berukuran 3 x 3, yang berarti model memindai gambar kotak demi kotak kecil untuk menemukan kejanggalan.

3. Max Pooling Layers (Lapisan Peringkas) Setelah setiap proses konvolusi, dilakukan proses Pooling. Lapisan ini bertugas memperkecil ukuran gambar dengan hanya mengambil nilai (pixel) yang paling menonjol/kuat. Tujuannya agar komputasi lebih ringan dan model fokus pada fitur-fitur yang benar-benar penting saja.

4. Flatten & Dense Layers (Lapisan Klasifikasi)

Flatten: Mengubah data gambar 2 dimensi menjadi deretan angka 1 dimensi (vektor) agar bisa diproses oleh "otak" model.

Dense Layer (64 Neuron): Ini adalah "otak" yang memproses semua informasi fitur yang telah dikumpulkan untuk mencari hubungan antara pola spektral dan label (Asli/Palsu). Output Layer (Keputusan Akhir) Lapisan terakhir hanya memiliki 1 Neuron dengan fungsi aktivasi Sigmoid.

- Fungsi ini akan mengeluarkan angka probabilitas antara 0 hingga 1.
- Jika hasil mendekati 0, model yakin itu suara Real (Asli).
- Jika hasil mendekati 1, model yakin itu suara Fake (Palsu).

3.4.2 Konfigurasi Pelatihan (Hyperparameters)

Agar model dapat belajar dengan baik, digunakan pengaturan sebagai berikut:

- Optimizer: Menggunakan Adam. Algoritma ini dipilih karena mampu menyesuaikan kecepatan belajar secara otomatis, sehingga model cepat pintar (konvergen) namun stabil.
- Loss Function: Menggunakan Binary Crossentropy. Fungsi ini adalah standar untuk masalah klasifikasi "Ya/Tidak" (Binary), yang bertugas menghitung seberapa jauh kesalahan tebakan model dibandingkan kunci jawaban yang sebenarnya.

BAB IV HASIL DAN PEMBAHASAN


4.1 Analisis Visual Karakteristik Sinyal

Sebelum dilakukan klasifikasi otomatis menggunakan model kecerdasan buatan (CNN), tahap pertama yang dilakukan adalah analisis visual terhadap sinyal audio. Analisis ini bertujuan untuk membuktikan secara kualitatif bahwa transformasi sinyal dari domain waktu ke domain frekuensi (PSD) memang diperlukan untuk membedakan suara asli dan palsu.

Pada bagian ini, dilakukan perbandingan visual antara bentuk gelombang (waveform) dan representasi spektral (Log-Mel Spectrogram).

4.1.1 Perbandingan Domain Waktu dan Frekuensi

Dalam pengolahan sinyal audio, informasi seringkali tersembunyi dan tidak terlihat jika hanya dilihat dalam bentuk gelombang biasa. Gambar di bawah ini memperlihatkan satu sampel audio yang sama, namun ditampilkan dalam dua domain yang berbeda.



Berdasarkan gambar di atas, dapat diamati fenomena menarik:


1. Pada Grafik Atas (Domain Waktu): Baik sinyal Real maupun Fake memiliki bentuk gelombang amplitudo yang sangat mirip. Secara kasat mata, sulit sekali menentukan mana suara manusia dan mana buatan mesin hanya dengan melihat naik-turunnya gelombang.

2. Pada Grafik Bawah (Domain Frekuensi/Spektrogram): Setelah sinyal ditransformasikan menggunakan metode STFT dan dipetakan ke Skala Mel, perbedaan mulai terlihat. Distribusi warna yang merepresentasikan energi suara menunjukkan pola yang lebih detail.

Hal ini membuktikan hipotesis awal penelitian bahwa analisis pada domain waktu saja tidak cukup efektif untuk mendeteksi Deepfake. Diperlukan transformasi ke domain frekuensi untuk melihat struktur internal suara tersebut.

4.1.2 Komparasi Spektrogram: Asli vs Palsu (Real vs Fake)

Setelah memastikan bahwa domain frekuensi memberikan informasi yang lebih kaya, langkah selanjutnya adalah membandingkan karakteristik spektral antara suara asli dan palsu secara head-to-head.



Dari perbandingan visual kedua spektrogram di atas, ditemukan beberapa karakteristik pembeda (artefak) yang menjadi ciri khas:

1. Karakteristik Suara Asli (Real):

- Kontinuitas: Pola frekuensi tampak lebih halus dan menyatu, menunjukkan transisi alami antar fonem.
- Distribusi Energi: Energi tersebar merata di berbagai frekuensi, terutama di rentang 0–4000 Hz.
- Minim Artefak Vertikal: Tidak tampak garis-garis vertikal yang tajam, menandakan tidak ada segmentasi digital yang kasar.

3. Karakteristik Suara Palsu (Fake/Deepfake):

- Segmentasi Vertikal: Terlihat garis-garis vertikal yang lebih tajam dan berulang, menunjukkan adanya proses stitching atau sintesis fonem.
- Noise Frekuensi Tinggi: Terdapat aktivitas yang tidak wajar di frekuensi >6000 Hz, yang sering menjadi indikator artefak sintesis.


- Pola Tidak Alami: Beberapa area menunjukkan intensitas warna yang melonjak tiba-tiba, menandakan ketidaksesuaian temporal.

Spektrogram Fake menunjukkan jejak digital yang bisa dimanfaatkan untuk klasifikasi menggunakan CNN. Perbedaan pola frekuensi dan distribusi energi antara suara asli dan palsu dapat menjadi fitur utama dalam sistem deteksi deepfake audio.

4.2 Hasil Pelatihan Model (Training Performance)

Setelah dilakukan analisis karakteristik sinyal, tahap selanjutnya adalah pelatihan model Convolutional Neural Network (CNN). Model dilatih menggunakan data latih (Training Set) dan divalidasi kinerjanya secara berkala menggunakan data validasi (Validation Set) pada setiap epoch.

Grafik di bawah ini memvisualisasikan riwayat pembelajaran model, yang mencakup pergerakan nilai Akurasi (Accuracy) dan Loss (tingkat kesalahan) selama proses pelatihan berlangsung.



Berdasarkan grafik kinerja di atas, dapat dilakukan analisis sebagai berikut:

1. Peningkatan Akurasi yang Konsisten (Konvergensi): Pada grafik sebelah kiri (Accuracy), terlihat bahwa garis akurasi baik untuk data latih (garis biru) maupun validasi (garis oranye) bergerak naik secara signifikan sejak epoch awal. Hal ini menunjukkan bahwa arsitektur CNN yang dirancang mampu menangkap fitur-fitur penting dari Log-Mel Spectrogram dengan cepat. Model tidak mengalami kesulitan berarti dalam membedakan pola visual antara suara asli dan palsu.
2. Kemampuan Generalisasi (Tidak Overfitting): Salah satu indikator kesehatan model yang paling penting adalah jarak (gap) antara garis Training dan Validation.
 - Jika garis Training naik tinggi tapi garis Validation turun/stagnan, itu tandanya Overfitting (model hanya menghafal).
 - Pada grafik hasil penelitian ini, kedua garis bergerak beriringan dan saling berdekatan. Ini menandakan bahwa model memiliki kemampuan generalisasi.

yang sangat baik. Artinya, model benar-benar "paham" membedakan suara, bukan sekadar menghafal data latihan.

3. Penurunan Nilai Loss: Grafik sebelah kanan (Loss) menunjukkan penurunan yang tajam di awal dan melandai mendekati angka nol (asimtotik). Penurunan Loss yang stabil pada data validasi membuktikan bahwa model semakin sedikit melakukan kesalahan prediksi seiring berjalannya waktu pelatihan.

Hasil pelatihan yang stabil ini memberikan landasan yang kuat untuk melangkah ke tahap pengujian akhir (Testing), dengan ekspektasi bahwa model akan memberikan performa yang handal pada data baru.


4.3 Evaluasi Kinerja Sistem (Testing Evaluation)

Setelah model dianggap matang melalui proses pelatihan, tahap krusial berikutnya adalah pengujian akhir. Pengujian dilakukan menggunakan Testing Set yang berisi 1.088 sampel audio (544 sampel Real dan 544 sampel Fake) yang belum pernah dilihat sama sekali oleh model sebelumnya.

Evaluasi ini bertujuan untuk mengukur seberapa handal sistem jika diterapkan pada skenario dunia nyata. Analisis dilakukan menggunakan dua instrumen statistik utama: Confusion Matrix dan Laporan Klasifikasi.

4.3.1 Analisis Confusion Matrix

Confusion Matrix memberikan gambaran detail mengenai distribusi prediksi model: mana yang benar, mana yang meleset, dan jenis kesalahan apa yang dibuat.



Berdasarkan visualisasi matriks di atas, dapat dianalisis distribusi prediksi sebagai berikut:

1. True Positive (Deteksi Deepfake Sukses): Kotak kanan-bawah menunjukkan jumlah audio Fake yang berhasil dideteksi sebagai Fake. Warna biru yang pekat di area ini menandakan bahwa mayoritas serangan berhasil digagalkan.

2. False Negative (Kebobolan/Miss): Kotak kiri-bawah menunjukkan audio Fake yang lolos deteksi (dianggap Real). Jumlahnya relatif kecil dibandingkan yang terdeteksi. Ini indikator keamanan yang baik.
3. False Positive (Salah Tuduh): Kotak kanan-atas menunjukkan audio Real yang dicurigai sebagai Fake. Dalam konteks keamanan siber, kesalahan jenis ini (False Alarm) lebih bisa ditoleransi daripada kebobolan (False Negative).

4.3.2 Classification Report

Untuk menerjemahkan matriks di atas menjadi angka kinerja yang terukur, berikut adalah tabel metrik evaluasi lengkapnya:

	precision	recall	f1-score	support
Real	0.90	0.82	0.86	544
Fake	0.84	0.91	0.87	544
accuracy			0.86	1088
macro avg	0.87	0.86	0.86	1088
weighted avg	0.87	0.86	0.86	1088

Berdasarkan tabel hasil pengujian di atas, performa sistem dapat disimpulkan pada tiga poin kunci:

1. Akurasi Total (Accuracy): 86% Secara keseluruhan, sistem mampu membedakan suara manusia asli dan sintetis dengan tingkat keberhasilan 86%. Angka ini membuktikan bahwa metode Log-Mel Spectrogram sangat efektif dalam mengekspos fitur-fitur tersembunyi yang membedakan kedua kelas tersebut.
2. Recall pada Kelas Fake: 91% (0.91) Ini adalah pencapaian terpenting dalam penelitian ini. Nilai Recall 0.91 pada label Fake berarti sistem memiliki sensitivitas sebesar 91% terhadap serangan.
 - Artinya: Dari setiap 100 percobaan serangan Deepfake yang masuk, sistem berhasil memblokir 91 di antaranya. Tingkat keamanan yang tinggi ini sangat krusial untuk mencegah penipuan identitas suara.
3. Precision pada Kelas Real: 90% (0.90) Nilai ini menunjukkan kredibilitas sistem saat memverifikasi pengguna asli. Jika sistem menyatakan sebuah audio adalah "Asli", maka 90% kemungkinannya audio tersebut memang benar-benar valid. Hal ini penting untuk menjaga kenyamanan pengguna (user experience) agar tidak terlalu sering ditolak saat login.


Secara umum, kombinasi Akurasi 86% dan Recall Fake 91% menunjukkan bahwa sistem yang dibangun tidak hanya "pintar", tetapi juga "aman".

4.4 Pembahasan (Discussion)

Berdasarkan hasil pengujian yang menunjukkan akurasi 86% dan Recall 91%, bagian ini akan membedah lebih dalam mengenai mengapa metode ini bisa berhasil. Analisis dilakukan dengan melihat perilaku statistik data secara keseluruhan, bukan hanya per sampel.

4.4.1 Analisis Pola Spektral Rata-Rata (Average Spectral Patterns)

Salah satu pertanyaan mendasar dalam penelitian ini adalah: "Apakah perbedaan antara suara asli dan palsu itu konsisten secara spektral?" Untuk menjawab pertanyaan tersebut, dilakukan teknik Signal Averaging terhadap seluruh dataset latih, yaitu dengan menghitung rata-rata spektrogram dari masing-masing kelas: suara asli (REAL) dan suara palsu (FAKE).



Gambar ini menampilkan tiga spektrogram hasil rata-rata dari ribuan sampel audio:

- Panel Kiri (Rata-rata Spektrogram REAL):

Menunjukkan distribusi energi yang dominan di rentang frekuensi rendah hingga menengah (0–4000 Hz), yang merupakan wilayah frekuensi utama dalam fonetik manusia. Pola spektral tampak halus dan berkesinambungan, mencerminkan transisi alami antar fonem.

- Panel Tengah (Rata-rata Spektrogram FAKE):

Secara umum menyerupai pola suara asli, namun terdapat perbedaan signifikan pada detail tekstur spektral. Terlihat adanya segmentasi vertikal dan penurunan intensitas pada beberapa transisi frekuensi, yang mengindikasikan ketidaksempurnaan dalam proses sintesis suara.


- Panel Kanan (Selisih Spektrogram REAL - FAKE):

Menampilkan peta perbedaan intensitas antara suara asli dan palsu. Warna merah menunjukkan area di mana suara asli memiliki energi lebih tinggi, sedangkan biru menunjukkan kelebihan energi pada suara palsu. Pola ini mengungkap bahwa perbedaan paling konsisten terjadi pada frekuensi menengah (4000–8129 Hz), yang sering kali gagal ditiru oleh algoritma deepfake. Perbedaan ini menjadi fitur penting yang dimanfaatkan oleh model CNN dalam proses klasifikasi.

Hasil analisis ini menunjukkan bahwa meskipun suara palsu dapat menyerupai suara asli secara umum, terdapat jejak spektral yang konsisten yang membedakan keduanya. Teknik averaging spektrogram terbukti efektif dalam mengungkap pola-pola ini secara visual dan kuantitatif.

4.4.2 Analisis Distribusi Energi (Energy Distribution Statistics)

Selain pola visual, karakteristik numerik sinyal juga dianalisis menggunakan Histogram Distribusi Intensitas Energi. Analisis ini bertujuan untuk mengidentifikasi perbedaan statistik antara sinyal suara asli dan palsu berdasarkan sebaran nilai amplitudo (dalam satuan desibel).



Histogram ini menampilkan distribusi intensitas energi yang telah dinormalisasi, dengan sumbu X menunjukkan rentang intensitas dari -80 dB hingga 0 dB, dan sumbu Y menunjukkan frekuensi kemunculan relatif.

- Kurva Biru (Real Audio Energy):

Menunjukkan distribusi yang lebih merata, dengan puncak intensitas berada di sekitar -45 dB. Hal ini mencerminkan dinamika suara manusia yang alami, di mana variasi amplitudo terjadi secara kontinu dan tidak terstruktur.

- Kurva Merah (Fake Audio Energy):

Memiliki puncak tajam di intensitas rendah sekitar -80 dB, menunjukkan bahwa sinyal palsu cenderung memiliki lebih banyak komponen energi yang sangat lemah. Ini mengindikasikan adanya penurunan dinamika akibat proses normalisasi atau kompresi yang dilakukan oleh algoritma pembangkit suara seperti vocoder atau TTS.

- Pergeseran Distribusi (Distribution Shift):

Perbedaan bentuk histogram antara suara asli dan palsu menunjukkan adanya pergeseran distribusi energi. Sinyal palsu cenderung memiliki distribusi yang lebih

sempit dan terpusat di intensitas rendah, sedangkan sinyal asli lebih menyebar dan bervariasi.

Temuan ini memperkuat efektivitas fitur Log-Mel Spectrogram, karena transformasi logaritmik terhadap amplitudo mampu menonjolkan perbedaan intensitas secara visual dalam bentuk warna kontras. Dengan demikian, fitur ini sangat berguna dalam proses klasifikasi suara palsu menggunakan model pembelajaran mesin seperti CNN.

4.4.3 Keterbatasan Model

Meskipun performa sistem sudah baik (Akurasi 86%), masih terdapat celah kesalahan sekitar 14%. Kesalahan ini kemungkinan disebabkan oleh:

1. Kualitas Rekaman Asli yang Buruk: Beberapa data Real mungkin memiliki noise latar belakang yang tinggi, sehingga pola spektralnya menyerupai artifak Deepfake.
2. Deepfake Generasi Baru: Algoritma pembuat suara palsu terus berkembang menjadi semakin canggih, sehingga jejak spektralnya semakin tipis dan sulit dibedakan oleh model yang hanya dilatih dengan dataset standar.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pengujian sistem yang telah dilakukan, dapat disimpulkan bahwa penerapan metode transformasi spektral Log-Mel Spectrogram yang dikombinasikan dengan arsitektur Convolutional Neural Network (CNN) terbukti efektif sebagai solusi deteksi Deepfake Audio. Sistem yang dibangun berhasil membedakan suara manusia asli (Real) dan suara sintetis (Fake) dengan tingkat akurasi mencapai 86%. Lebih spesifik lagi, sistem menunjukkan sensitivitas yang sangat tinggi terhadap upaya manipulasi suara, yang dibuktikan dengan nilai Recall sebesar 91% pada kelas Fake. Hal ini mengindikasikan bahwa transformasi sinyal ke domain frekuensi (Skala Mel) mampu mengungkap jejak digital atau artifak visual halus yang seringkali tidak terdengar oleh telinga manusia namun terlihat jelas pada pola distribusi energi spektrogram.

Keberhasilan model ini juga sangat dipengaruhi oleh konsistensi pada tahapan pra-pemrosesan sinyal (Signal Pre-processing), khususnya proses penyeragaman durasi audio menjadi 2 detik dan normalisasi amplitudo yang terbukti menjaga stabilitas proses pembelajaran model. Meskipun demikian, penelitian ini masih mencatat adanya keterbatasan berupa tingkat kesalahan (error rate) sebesar 14%. Angka ini menunjukkan bahwa penggunaan analisis spektral tunggal, meskipun handal untuk mayoritas kasus, masih memiliki celah deteksi saat dihadapkan pada variasi data yang ekstrim atau rekaman dengan kualitas rendah (noisy), sehingga masih terbuka ruang untuk pengembangan lebih lanjut guna menutup celah keamanan tersebut.

REFERENSI

- [1] B. Zhang, H. Cui, V. Nguyen, and M. Whitty, "Audio Deepfake Detection: What Has Been Achieved and What Lies Ahead," *Sensors*, vol. 25, no. 7, p. 1989, 2025.
- [2] L. Pham, P. Lam, T. Nguyen, H. Nguyen, and A. Schindler, "Deepfake Audio Detection Using Spectrogram-based Feature and Ensemble of Deep Learning Models," *arXiv preprint*, arXiv:2407.01777, 2024.
- [3] E. Hassan, S. Abu Ghazalah, F. Al-Shehri, and S. Qadir, "Optimizing Deepfake Audio Detection: Fragment Feature Overlaid Quantization Model for High Accuracy and Efficiency," *International Journal of Machine Learning and Cybernetics*, vol. 16, pp. 8933–8952, 2025.
- [4] M. K. Z. Bajwa, A. Castiglione, and C. Pero, "Mel Spectrogram-Based CNN Framework for Explainable Audio Deepfake Detection," *Journal of Information Security and Applications*, vol. 78, 2025.
- [5] P. Kumar and R. Singh, "Spectrogram Analysis for Speech Signal Processing," *International Journal of Speech Technology*, vol. 27, no. 2, pp. 145–158, 2024.
- [6] S. D. Voran, "Why Some Audio Signal Short-Time Fourier Transform Coefficients Have Nonuniform Phase Distributions," in *Proc. IEEE ICME*, 2024.
- [7] E. T. Ogidan, O. P. Olawale, and K. Dimililer, "Short-Time Fourier Transform in Audio Recognition Applications," in *Lecture Notes in Networks and Systems*, vol. 1142, Springer, 2025, pp. 171–177.
- [8] H. Tak, J. Patino, and N. Evans, "End-to-End Convolutional Neural Network Based Detection of Synthetic Speech," in *Proc. Interspeech*, 2021, pp. 4813–4817.
- [9] B. Zhang et al., "Audio Deepfake Detection: What Has Been Achieved and What Lies Ahead," *Sensors*, vol. 25, no. 7, p. 1989, 2025.
- [10] M. K. Z. Bajwa et al., "Mel Spectrogram-Based CNN Framework for Explainable Audio Deepfake Detection," *Journal of Information Security and Applications*, vol. 78, 2025.
- [11] E. Hassan et al., "Optimizing Deepfake Audio Detection: Fragment Feature Overlaid Quantization Model for High Accuracy and Efficiency," *International Journal of Machine Learning and Cybernetics*, vol. 16, pp. 8933–8952, 2025.

LAMPIRAN

<https://github.com/Underag3/ANALISIS-KARAKTERISTIK-SPEKTRAL-SINYAL-AUDIO-DEEPFAKE-MENGGUNAKAN-METODE-STFT>